深度研究报告

视频笔记可视化链路深度研究

从字幕之后到高质量 PDF：对现有 skill / runtime 的诊断、外部方案扫描与改造路线

Codex

2026-03-26

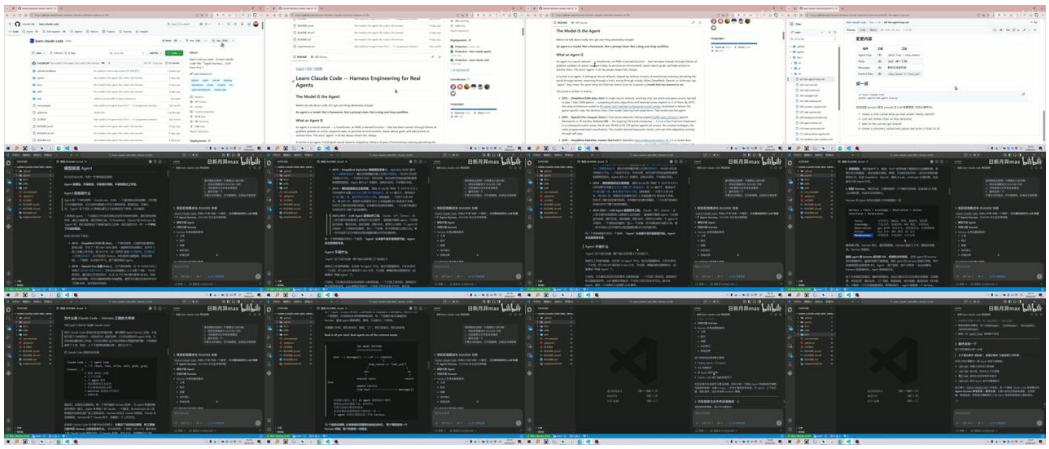

核心问题：如何优化 video-note skill 与 video-note-pipeline 在“字幕获取之后”的可视化链路，使 agent 更稳定地产出逻辑连贯、图像清晰、来源可追踪的高质量 PDF?

研究范围：聚焦字幕之后的视觉与排版阶段：视频定位、候选帧搜索、裁剪与 OCR、图文规划、PDF 构建、联网增益、评测体系。证据来自本地两个实现、多个历史 case，以及截至 2026-03-26 的公开官方文档与项目资料。

目标读者：video-note skill / runtime 的维护者，以及需要把视频系统化沉淀为研究型 PDF 的 agent 设计者

证据窗口：本地仓库状态截至 2026-03-26；外部网页资料访问日期为 2026-03-26

目录

1 执行摘要 **3**

2 研究范围与方法 **3**

2.1 研究对象与时间边界 3

2.2 方法 4

2.3 研究问题拆解 4

3 当前实现与案例证据 **4**

3.1 旧 skill 的优点：原则完整，但执行主要靠 agent 4

3.2 新 runtime 的优点：壳已经搭好，但视觉中间层缺失 5

3.3 案例证据一：`static-outline` 视频应尽早切换策略 5

3.4 案例证据二：`board-heavy` 长视频最需要分层抽帧，而不是逐张回源精抓 7

3.5 案例证据三：`commentary` 视频里 OCR 可能几乎完全失效 7

4 外部方案调研：每个环节有哪些成熟方案 **7**

4.1 关键帧定位与视频切分 7

4.1.1 FFmpeg：最便宜、最稳的底座 7

4.1.2 PySceneDetect：适合把 transcript window 进一步切细 8

4.1.3 TransNetV2：适合做强镜头边界，不适合单独承担教学图定位 8

4.1.4 Lecture2Notes：最接近“教学视频里的字幕后可视化链路” 8

4.1.5 video2slides / YouTube slide extractor：轻量 baseline 的价值 9

4.2 裁剪、OCR 与版面理解 9

4.2.1 先回答用户的第一个问题：不是“不能 crop”，而是没把 crop 做成产物 9

4.2.2 PaddleOCR：布局和公式页最值得优先借的外部能力 9

4.2.3 docTR 与 LayoutParser：更适合做可选探针，而不是默认主线 10

4.2.4 建议固定四类图，而不是让 agent 每次临场发明 10

4.3 图文规划与中间表示：这是最关键的一层 10

4.3.1 PPT-master 给出的最大启发：先建中间表示，再导出目标文档 10

4.3.2 建议新增的五个中间层 11

4.3.3 推荐的 figure 评分函数 11

4.4 PDF 构建：保留 LaTeX，重构输入层 11

4.4.1 为什么不建议现在就迁移到 Typst 或 Quarto 11

4.4.2 为什么现有模板里的 provenance 推荐写法应调整 12

4.5 联网增强：应该做，但必须模式化 12

4.5.1 建议的三档联网策略 13

4.5.2 为什么它不应该发生在 build 阶段 13

5 逐条回答用户的五个问题 **13**

5.1 1. 图片处理工具是不是不够，不能 crop? 13

5.2 2. 视频处理是否不够好，导致定位不准? 13

5.3 3. PDF 构建是否有更好的方式让逻辑更连贯? 14

5.4 4. 构建 PDF 时是否可以联网搜索更多资源? 14

5.5 5. 历史 case 是否应该进一步利用? 14

6 建议的目标架构 **14**
6.1 总体设计：从字幕到 PDF 的六层链路 14
6.2 建议扩展的模式分类 14
6.3 针对每种模式的 figure workflow 15
6.3.1 `static-outline` 15
6.3.2 `board-heavy` 15
6.3.3 `screen-demo` 15
6.3.4 `commentary / analysis` 15
6.4 推荐的目录树与 artifact 合约 16
6.5 PDF QA：不要再停在“编过就算” 16

7 实施路线：按 ROI 排序 **17**
7.1 P0：先补最值钱的中间层 17
7.2 P1：引入 probe 型视觉增强 17
7.3 P2：引入更强的语义规划 17
7.4 P3：评估更远期替代方案 17

8 评测集与验收指标 **17**
8.1 建议先固化四个 benchmark case 17
8.2 不要只测“能否出 PDF” 18
8.3 建议的最小回归测试 19

9 风险、边界与不建议做的事 **19**
9.1 不要在没有中间层之前盲目上重型视觉模型 19
9.2 不要把 OCR 当作所有视频的默认解 19
9.3 不要让联网增强改写“忠实讲义”的基本契约 19
9.4 不要把最好的 case 误当成“流程天然稳定产物” 20

10 结论与后续问题 **20**
10.1 已经有充分证据支持的结论 20
10.2 大概率正确但仍值得继续验证的推断 20
10.3 下一步最值得做的三件事 20

A 来源清单 **20**

B 一个可直接执行的最小技术任务单 **22**

1 执行摘要

核心结论

当前链路的主要瓶颈不是“字幕之后没有任何工具”，而是“字幕之后没有稳定的中间层”。旧 `video-note-skill` 已经写出了高质量 figure workflow 的原则，但主要依赖执行者手工执行；新的 `video-note-pipeline` 则把 preflight / transcript / overview / build 结构化了，却还没有把 figure planning、候选帧密集搜索、裁剪、manifest、叙事构建、PDF QA 变成 runtime 能直接产出的确定性步骤。

- 现有 runtime 在字幕之后真正拥有的能力，主要只有均匀抽样 overview、Pillow montage、基于重复率和熵的粗 mode heuristic，以及 LaTeX 编译包装；这对于“先粗分视频类型”足够，但对“稳定产出高质量 PDF”明显不够。
- 本地 case 已经给出清晰证据：`static-outline` 视频需要尽早放弃密集原始截图，转向少量高价值裁剪图与 TikZ；`board-heavy` 长视频需要 `candidate -> montage -> crop-first` 的分层策略；`commentary` 视频里 OCR 大规模失效，应转向“正文主导 + 少量 representative frames + 自制结构图”。
- 外部项目和官方文档说明，可用方案非常丰富，但应按层接入。P0 阶段并不需要重型 CV 栈，只要把 `ffmpeg + Pillow + manifest` 产品化，就能获得最大一批收益；P1 再引入 PySceneDetect、PaddleOCR layout / formula、可选的 OCR / layout probes；P2 再考虑 VLM 或学习型 shot boundary。
- 对 PDF 渲染层的建议不是“马上换掉 LaTeX”，而是“保留 LaTeX、重构输入中间层”。与其直接从 transcript 跳到 `note.tex`，不如先生成 `outline.json`、`claims.json`、`figure_plan.json`、`frame_manifest.json`、`render_context.json`，再渲染 TeX。
- 联网增强值得做，但不应塞到最后 build 阶段，而应放到 claims 定稿前，并且必须模式化控制：忠实讲义默认关闭或仅补拓展阅读；评论 / 分析 / 证据敏感视频才开启外部事实核验与背景补全。

最重要的工程决策

如果直接补很多模型和工具，却不先定义 artifact contract，最后只会把人工 figure workflow 变成更复杂的人工 figure workflow。应先固定流程产物，再增加模型能力。

2 研究范围与方法

2.1 研究对象与时间边界

本报告聚焦于“字幕已经拿到之后”的阶段，即：

- transcript 如何转成教学单元、章节与论点；
- 如何从视频中定位候选图、搜索最终帧、做 crop；
- 如何在 PDF 中把截图、重绘图、表格、正文、provenance 组织成逻辑更连贯的文档；
- 是否以及如何在这一阶段引入联网检索来增强背景、佐证或纠错。

本地实现包括：

- 旧 skill：`/home/fanghaotian/.codex/skills/video-note-skill/skills/bilibili-render-pdf/SKILL.md`
- 当前 runtime：`/home/fanghaotian/Desktop/src/video-note-pipeline`
- 当前统一 wrapper：`/home/fanghaotian/Desktop/src/agent-basic-skill/skills/video-note-render-pdf`
- 历史 case：`/home/fanghaotian/Desktop/src/video_notes`

2.2 方法

证据构成

- 本地代码与模板：检查 runtime 真实能力边界，以及 skill 当前的写作与 figure 规则。
- 本地 retrospective 与案例：提取真实运行中的断点、补救动作、稳定有效的经验。
- 外部官方文档 / 官方仓库：调研 scene detection、slide extraction、OCR / layout、PDF authoring、文档中间表示等主流方案。
- 综合判断：在“你们现在已有 skill / runtime / case 资产”的约束下，优先选择最小改动、最高 ROI 的升级路线，而不是理论上最强但工程代价过高的方案。

2.3 研究问题拆解

用户在本轮讨论里提出了五个直觉问题，本报告将逐一回答：

1. 图片处理工具是否不够，尤其是不方便 crop?
2. 视频处理是否不够好，导致定位关键图片不准?
3. PDF 构建是否还有更好的方式，让逻辑更连贯、动机更清晰?
4. 构建 PDF 时是否应该联网搜索，以获得额外资源和背景?
5. 历史 case 能否被系统化为评测集与流程约束?

3 当前实现与案例证据

3.1 旧 skill 的优点：原则完整，但执行主要靠 agent

旧 `bilibili-render-pdf` 在规则层面对 figure handling 的描述其实很强。它明确要求：

- 以字幕时间窗作为关键帧定位主线；
- 先高召回搜索候选，再人工下采样；
- 对渐进式 reveal、白板累积、界面变化要找最终完整可读状态；
- 必要时 crop；

- 对难以用截图解释的内容补 TikZ / PGFPlots 或脚本生成图；
- 记录视频图像的时间区间 provenance。

这些规则见 `/home/fanghaotian/.codex/skills/video-note-skill/skills/bilibili-render-pdf/SKILL.md` 的 Figure Handling 与 Visualization 段落。问题不在理念，而在于这些步骤还没有被落为 runtime artifact，因此无法稳定复用。

3.2 新 runtime 的优点：壳已经搭好，但视觉中间层缺失

当前 `video-note-pipeline` 的优点，是已经把 preflight、subtitle / transcript 获取、overview、build 这些“壳”结构化了。但字幕之后真正自动化的部分只有四个：

- `extract_overview_frames`: 对整段视频均匀抽样；
- `build_montage`: 用 Pillow 做缩略图拼版；
- `infer_recommended_mode`: 用重复率、熵、相邻差分做粗 heuristic；
- `build_note`: 执行 LaTeX 编译与预览导出。

这从 `/home/fanghaotian/Desktop/src/video-note-pipeline/src/video_note_pipeline/frames/overview.py`、`/home/fanghaotian/Desktop/src/video-note-pipeline/src/video_note_pipeline/commands.py`、`/home/fanghaotian/Desktop/src/video-note-pipeline/src/video_note_pipeline/build/latex.py` 可以直接确认。

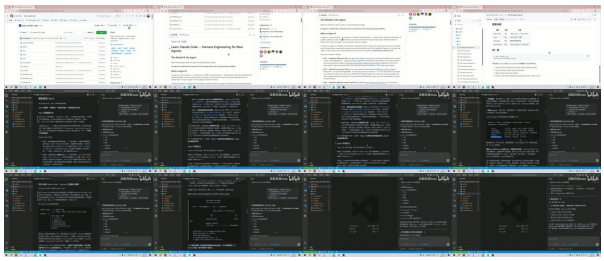

(a) 当前 runtime 的 overview montage

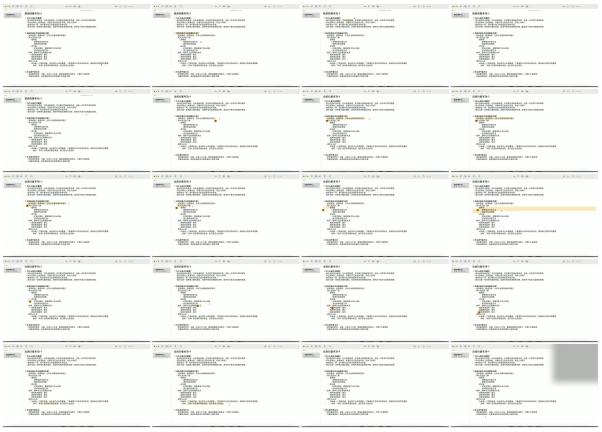

(b) 真实 case 中能快速识别单页 outline 的 montage

图 1: 当前 overview 能帮助粗判断视频类型，但还不是“可直接进 PDF 的 figure workflow”。左图来自 runtime 的统一抽样产物；右图来自 `BV1cptBzFE5Q` case，已经足以驱动策略切换。

来源：左图本地路径 `/home/fanghaotian/Desktop/src/video-note-pipeline/reports/2026-03-25-apply-review-bv1g5aazheh3/figures/overview-montage.jpg`；右图本地路径 `/home/fanghaotian/Desktop/src/video_notes/BV1cptBzFE5Q/contacts/overview_montage.jpg`。

3.3 案例证据一：`static-outline` 视频应尽早切换策略

`BV1cptBzFE5Q` 的 retrospective 证明了一个关键点：overview montage 一旦已经显示“画布几乎不变、靠同一页大纲高亮推进”，后续就不该继续走“按章节密集抽大量候选图”的默认路线。真正有效的路径是：

- 保留一张完整大纲页；
- 只抽少量高价值裁剪图；
- 用 TikZ 和结构化重写承担解释任务；
- 对 provenance 使用图下内嵌小号来源说明，而不是 `figure + footnotetext`。

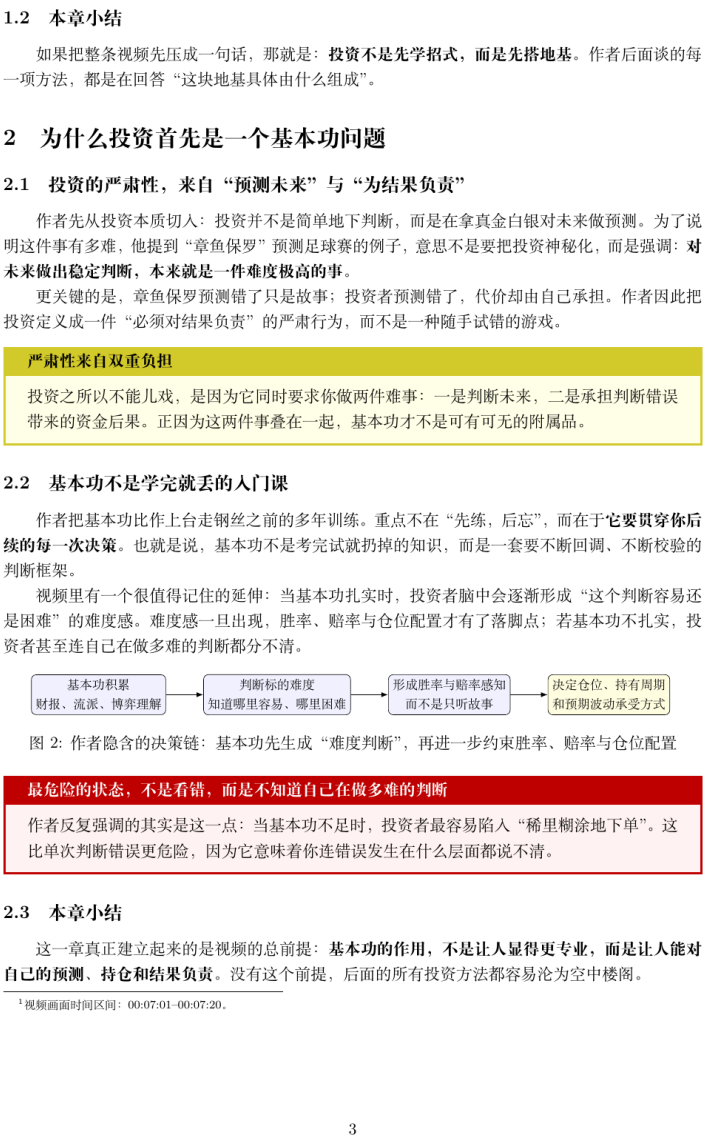

1.2 本章小结

如果把整条视频先压成一句话，那就是：**投资不是先学招式，而是先搭地基**。作者后面谈的每一项方法，都是在回答“这块地基具体由什么组成”。

2 为什么投资首先是一个基本功问题

2.1 投资的严肃性，来自“预测未来”与“为结果负责”

作者先从投资本质切入：投资并不是简单地下判断，而是在拿真金白银对未来做预测。为了说明这件事有多难，他提到“章鱼保罗”预测足球赛的例子，意思不是要把投资神秘化，而是强调：**对未来做出稳定判断，本来就是一件难度极高的事**。

更关键的是，章鱼保罗预测错了只是故事；投资者预测错了，代价却由自己承担。作者因此把投资定义成一件“必须对结果负责”的严肃行为，而不是一种随手试错的游戏。

严肃性来自双重负担

投资之所以不能儿戏，是因为它同时要求你做两件难事：一是判断未来，二是承担判断错误带来的资金后果。正因为这两件事叠在一起，基本功才不是可有可无的附属品。

2.2 基本功不是学完就丢的入门课

作者把基本功比作上台走钢丝之前的多年训练。重点不在“先练，后忘”，而在于**它要贯穿你后续的每一次决策**。也就是说，基本功不是考完试就扔掉的知识，而是一套要不断回调、不断校验的判断框架。

视频里有一个很值得记住的延伸：当基本功扎实时，投资者脑中会逐渐形成“这个判断容易还是困难”的难度感。难度感一旦出现，胜率、赔率与仓位配置才有了落脚点；若基本功不扎实，投资者甚至连自己在做多难的判断都分不清。

图 2: 作者隐含的决策链：基本功先生成“难度判断”，再进一步约束胜率、赔率与仓位配置

最危险的状态，不是看错，而是不知道自己在做多难的判断

作者反复强调的其实是这一点：当基本功不足时，投资者最容易陷入“稀里糊涂地下单”。这比单次判断错误更危险，因为它意味着你连错误发生在什么层面都说不清。

2.3 本章小结

这一章真正建立起来的是视频的总前提：**基本功的作用，不是让人显得更专业，而是让人能对自己的预测、持仓和结果负责**。没有这个前提，后面的所有投资方法都容易沦为空中楼阁。

[1] 视频画面时间区间：00:07:01–00:07:20。

3

图 2: `static-outline` case 的最终 PDF 页面，说明“少量裁剪图 + 结构化重绘 + 图下 provenance”是可行的稳定交付模式

来源：本地路径 `/home/fanghaotian/Desktop/src/video_notes/BV1cptBzFE5Q/pdf_preview/page-04.png`。页面底部已使用内嵌来源文字，而非漂移风险更高的 `\footnotetext`。

3.4 案例证据二：`board-heavy` 长视频最需要分层抽帧，而不是逐张回源精抓

`BV1tj6wBDEXF` 的 retrospective 和其 `frame_manifest.json` 表明，长 AV1 白板 / Excalidraw 视频里，真正高 ROI 的工作流是：

1. 先以较粗粒度产出大批候选图；
2. 用 montage 快速看完整个候选空间；
3. 候选图足够清晰时，直接 crop candidate；
4. 只有当候选图读不清时，才回到源视频做精确 seek。

这说明“图像工具不够”不是主问题。真正缺的是 runtime 是否内建了 tiered extraction，以及是否有 `frame_manifest.json` 记录每张最终图的来源、时间区间、crop 参数和用途。

3.5 案例证据三：`commentary` 视频里 OCR 可能几乎完全失效

`BV1VaQrBPEg9` 的 retrospective 记录了 403 张候选帧 OCR 全零的事实。这意味着：

- 对这种视频，继续扩大抽帧和 OCR 只会放大噪声；
- 最终高价值“图”通常不是视频截图，而是后补的表格、对比图、结构图；
- 因此 mode routing 必须有 `commentary / analysis` 分支，而不是强行套到 lecture / tutorial 的截图思路里。

从三个 case 能归纳出的稳定结论

- 不同视频类型需要完全不同的 figure strategy，不能只靠统一抽帧频率。
- OCR 应该是 probe，而不是默认主流程。
- 真正稳定的成果来自“图文规划 + 选帧中间层 + provenance”，而不是额外多抽几十张图。

4 外部方案调研：每个环节有哪些成熟方案

4.1 关键帧定位与视频切分

4.1.1 FFmpeg：最便宜、最稳的底座

FFmpeg 官方滤镜文档已经覆盖了当前链路最需要的几个底层能力：

- `fps=`：按固定频率抽帧；
- `thumbnail`：从一段帧里选代表帧；
- `cropdetect`：寻找黑边或稳定裁切边界；
- `select='gt(scene, x)'`：依据 scene score 做基础切分。

这意味着 P0 阶段并不缺基础工具。**缺的是把这些滤镜组织成分层策略**。对于当前项目，FFmpeg 足够承担：

- overview 抽样；
- 指定时间窗内的 dense candidate extraction；
- 对黑边、letterbox、固定边栏的初步裁切；
- 仅在必要时回源视频重抓高分辨率最终图。

4.1.2 PySceneDetect：适合把 transcript window 进一步切细

PySceneDetect 官方文档提供了 `ContentDetector`、`AdaptiveDetector`、`ThresholdDetector` 等检测器。它的价值不是“代替字幕对齐”，而是补上字幕没有描述的视觉切换点，例如：

- PPT 页切换；
- 屏幕录制中的明显界面变化；
- 镜头切换；
- 大纲页中的焦点区域跃迁。

我建议把它放在“teaching window 之后、dense candidates 之前”，让 agent 不是盲目在整个字幕段均匀抽样，而是只在真正发生视觉变化的局部区间提高采样密度。

4.1.3 TransNetV2：适合做强镜头边界，不适合单独承担教学图定位

TransNetV2 官方仓库提供了学习型 shot transition detection。它对电影、综艺、公开视频中的镜头边界很有价值，但对你们当前最重要的三类 case 有局限：

- `static-outline`：整页几乎不切镜头，真正重要的是局部高亮变化；
- `board-heavy`：白板是渐进累积，重要的是“最终完整状态”，不是 shot boundary；
- `commentary`：就算切镜头，也不代表对应知识图。

因此 TransNetV2 更适合作为可选增强，而不是第一优先级投入。

4.1.4 Lecture2Notes：最接近“教学视频里的字幕后可视化链路”

Lecture2Notes 文档和其 duplicate-image-removal 文档最值得借鉴的地方不在“直接抄实现”，而在流程设计：

- 先区分 slide frame 与非 slide frame；
- 对 slide 做黑边裁切、透视矫正；
- 用图像相似度做重复页去重；
- 把讲师遮挡、边缘黑框、相机角度等视频噪声当成显式问题来处理。

这对你们的启发是：**crop 不应该只是最后的“手工修一下”，而应成为 figure workflow 的第一等产物**。

4.1.5 video2slides / YouTube slide extractor：轻量 baseline 的价值

video2slides 这类项目展示了另一个现实：很多 slide 视频其实可以靠轻量遮罩、边缘剔除、相似度去重、代表帧筛选得到不错结果。它不一定是你们的最终解，但很适合做一个便宜 baseline，用来验证“当前 case 是否值得上更重的 OCR / layout / VLM”。

表 1: 关键帧定位方案对当前项目的适配性比较

方案	主要优势	局限	对当前项目建议
FFmpeg filters	成本最低、依赖已存在、可直接进 runtime	语义弱，需要手工组合	立即产品化，作为 P0 底座
PySceneDetect	适合发现字幕之外的视觉变化点	仍不理解“教学价值”	P1 接入，做 dense window 辅助
TransNetV2	学习型镜头边界更强	对单页 outline / 白板增益有限	P2 评估，不作为首要投入
Lecture2Notes 风格流程	最接近教学视频图像管线	体系偏重，需选择性借鉴	重点借鉴其 crop / dedup / slide filter 思路
video2slides 类工具	可做快速 baseline	对复杂案例天花板低	适合做 cheap probe，而非主线路

4.2 裁剪、OCR 与版面理解

4.2.1 先回答用户的第一个问题：不是“不能 crop”，而是没把 crop 做成产物

你提出“图片处理工具是不是不够、是不是不能 crop”，从现状看答案是否定的。现有依赖里已经有 Pillow，FFmpeg 也天然支持裁切；本地 case 也已经手工产出了高质量裁剪图。问题在于 runtime 没有下面这些确定性产物：

- `crop_proposal.json`
- `full-frame` 与 `detail-crop` 的并行导出
- `frame_manifest.json` 中的 crop 参数
- 对 crop 质量的最低检查，如文字可读性、重复度、上下文损失

4.2.2 PaddleOCR：布局和公式页最值得优先借的外部能力

PaddleOCR Layout Analysis 文档说明其 layout 模块可以给出页面区域结构。对你们最有价值的不是“把整张图 OCR 成文本”，而是：

- 帮你判断画面里哪里是标题、正文、图示、表格、代码、公式区域；
- 让 crop 不再只是凭肉眼估；
- 在 screen demo 和 slide page 里更稳定地切出主要信息区。

公式识别模块 对数学板书、PPT 公式页尤其重要。它不一定必须上到主流程，但对于公式密集 case，可以作为按需 probe。

4.2.3 docTR 与 LayoutParser：更适合做可选探针，而不是默认主线

docTR 是 OCR detection + recognition 工具，LayoutParser 则强调布局检测与可组装后处理。二者都适合作为 "probe 组件"：

- 当视频被路由到 `screen-demo`、`static-outline`、`document-heavy` 时启用；
- 当 OCR 得分、布局稳定性、文本面积超过阈值时再继续；
- 当进入 `commentary` 时直接跳过。

这比 "所有视频一律 OCR" 更合理，也更贴合本地 case 证据。

4.2.4 建议固定四类图，而不是让 agent 每次临场发明

建议把最终入 PDF 的图固定分成四种：

1. `full-frame`：保留完整上下文，例如整页大纲或整张白板。
2. `detail-crop`：只保留当前段落真正需要看的区域。
3. `progress-sequence`：当概念是逐步构建时，用一组 2–4 张图表示推进过程。
4. `synthetic-figure`：当截图本身说不清时，用 TikZ / 表格 / redrawn diagram 承担解释任务。

关于 crop 的结论

P0 阶段完全可以只靠 FFmpeg + Pillow + 规则化 crop manifest 获得显著提升；OCR / layout 的收益主要体现在 screen-demo、slide、document-heavy 和 formula-heavy 视频里，应做成按模式启用的 probe。

4.3 图文规划与中间表示：这是最关键的一层

4.3.1 PPT-master 给出的最大启发：先建中间表示，再导出目标文档

PPT-master README 最值得借鉴的地方，不是它做的是"文本到 PPT"而不是"视频到 PDF"，而是它明确采用了中间表示思想：先让 AI 输出结构化 SVG / scene，再转换为 PowerPoint 的 DrawingML，从而得到可编辑结果。

你们当前链路最大的问题，正好是少了这一层。现在很容易出现下面的跳跃：

$$\text{transcript / overview} \rightarrow \text{直接生成 } \texttt{note.tex}$$

这会导致：

- 哪一节该放什么图，没有显式约束；

- 哪张图为什么被选中，没有结构化记录；
- 章节动机、图的解释职责、外部证据增强都挤在生成正文这一步里；
- PDF 质量严重依赖 agent 当次发挥。

4.3.2 建议新增的五个中间层

表 2: 建议新增的核心 artifact

Artifact	作用	最低字段
`outline.json`	定义章节顺序与动机	section id, title, objective, source interval
`claims.json`	把正文拆成可核对的论点单元	claim id, section id, support type, transcript span, confidence
`figure_plan.json`	决定每一节需要什么图以及图承担什么解释职责	figure id, section id, role, preferred type, source window, must-have / optional
`frame_manifest.json`	记录最终图来源与 crop 信息	figure id, file, source, interval, frame time, crop, purpose
`render_context.json`	把上面几层变成 TeX 渲染输入	metadata, ordered sections, figure refs, callouts, references

4.3.3 推荐的 figure 评分函数

当一个时间窗里有多张候选图时，建议 runtime 先给出显式分数，agent 再决定是否覆写：

$$S(f,s) = \alpha R(f) + \beta A(f,s) + \gamma C(f) + \delta N(f) - \lambda D(f)$$

- $S(f,s)$：候选帧 f 在当前教学单元 s 下的综合分数
- $R(f)$：可读性，衡量文字大小、模糊程度、对比度
- $A(f,s)$：与当前字幕 / 章节窗口的对齐程度
- $C(f)$：内容完整度，尤其针对 progressive reveal / 白板累积
- $N(f)$：相对已选图的新增信息量
- $D(f)$：代价惩罚，例如必须重新 seek 源视频、OCR 失败或 crop 不稳定
- $\alpha, \beta, \gamma, \delta, \lambda$：根据模式路由设定的权重

这个函数不要求一开始就完美，但它会迫使 runtime 把“选图理由”变成显式数据，而不是全靠人的临场直觉。

4.4 PDF 构建：保留 LaTeX，重构输入层

4.4.1 为什么不建议现在就迁移到 Typst 或 Quarto

Typst 官方文档 和 Quarto PDF 文档 都说明它们各有优势：

- Typst 在现代写作体验、模板化、编译速度上更友好；
- Quarto 在研究报告、Markdown 驱动工作流、表格与数据可视化编排上很强；
- 但 Quarto 的高质量 PDF 仍依赖 LaTeX 引擎，而你们当前已有的中文模板、TikZ、callout、图片规则都已沉淀在 LaTeX 上。

因此当前最合理的路线不是更换 renderer，而是改造输入层：

- 让 TeX 只负责最后编排；
- 让叙事规划、figure plan、provenance、外部证据增强在 TeX 之前完成；
- 把 provenance 的默认写法从 `figure + footnotetext` 改成图下内嵌来源块。

4.4.2 为什么现有模板里的 provenance 推荐写法应调整

统一 wrapper 的模板注释目前仍推荐：

```
\begin{figure}[H]
\centering
\includegraphics[width=\textwidth]{...}
\caption{... \protect\footnotemark}
\end{figure}
\footnotetext{视频画面时间区间：00:12:31--00:12:46。}
```

Listing 1: 当前模板注释推荐的 provenance 模式

但本地 `BV1cptBzFE5Q` case 已经证明，这种写法在接近分页边界时会把来源说明挤到下一页，违背“图和来源留在同页”的要求。建议默认改成：

```
\begin{figure}[H]
\centering
\includegraphics[width=\textwidth]{figures/fig_xxx.jpg}
\caption{关键图：......}
\end{figure}
{\footnotesize
\noindent 来源：视频 00:12:31--00:12:46，原始候选图 chapter_0031.jpg，
最终使用裁剪参数 840x500+80+20。}
```

Listing 2: 建议的图下内嵌 provenance 模式

关于 PDF 引擎的结论

短中期不建议切换 Typst / Quarto。对你们当前项目，最大的 PDF 质量提升来自“结构化中间层 + route-specific 模板 + provenance 修正 + PDF QA”，而不是更换排版引擎。

4.5 联网增强：应该做，但必须模式化

你提出“构建 PDF 时是否可以上网搜索”这一点，我的判断是：**可以，而且在某些模式下非常值得；但不要放在最后 build 阶段，也不要对所有视频默认开启。**

4.5.1 建议的三档联网策略

表 3: 联网增强的模式化策略

模式	是否联网	建议行为
faithful lecture-note	默认关闭或仅补拓展阅读	保持对讲者叙事的忠实性，不主动纠正文稿主线
commentary / analysis	建议开启	区分视频原话、外部事实、整理者推断；对核心结论做背景补足与事实核验
evidence-sensitive	必须开启	对公共政策、金融、医学等内容优先引用一手来源，并显式记录证据链

4.5.2 为什么它不应该发生在 build 阶段

如果把联网放在 TeX 生成之后，通常只会造成两种坏结果：

- 找到的信息没有进入章节动机和图文结构，只能被硬塞成附录；
- 外部事实和视频原叙事被混写，最终失去 provenance。

更合理的做法是在 `claims.json` 定稿前，增加一个可选的 `evidence_enrichment.json`：

- 哪个 claim 需要外部来源；
- 使用了哪些网页 / PDF / 论文；
- 是 `corroborate`、`correct` 还是 `background-only`；
- 证据强弱与冲突情况如何。

5 逐条回答用户的五个问题

5.1 1. 图片处理工具是不是不够，不能 crop？

不是。现有工程已经具备 FFmpeg 与 Pillow，理论上完全能做 crop。真正的短板是缺少围绕 crop 的 workflow 和数据结构。现阶段最有效的升级不是再装一个图像库，而是：

- 把 crop proposal、crop variant、crop provenance 变成 runtime 产物；
- 给每张关键图至少保留 `full-frame` 与 `detail-crop` 两种版本；
- 对 screen-demo / slide / formula-heavy 视频再按需启用 OCR / layout probe。

5.2 2. 视频处理是否不够好，导致定位不准？

是，而且这是当前最明显的工程短板。现有 runtime 的定位本质上还是全片均匀抽样，只适合给 mode 提供初始建议，不适合直接产最终图。最需要增加的是：

1. 把 transcript 聚成教学单元，而不是逐条 subtitle 处理；
2. 结合 scene change、chapter 边界和语义峰值定位高价值窗口；

3. 在窗口内做 dense candidate extraction；
4. 候选图可读时先 crop candidate，只有必要时回源精抓。

5.3 3. PDF 构建是否有更好的方式让逻辑更连贯？

有，但关键不是换 PDF 引擎，而是先做中间层。我建议的核心变化是：不要再从 transcript 直接跳到 `note.tex`，而是先构建章节动机、论点列表、图的解释职责，再渲染模板。这样生成出来的 PDF 会更接近一份“研究型讲义”，而不是“把口播和截图堆在一起的长文”。

5.4 4. 构建 PDF 时是否可以联网搜索更多资源？

可以，但要按模式开关。对讲义型视频，联网更多是补“拓展阅读”；对评论 / 分析型视频，联网可以显著提升文档的背景层与证据质量；对证据敏感主题，甚至应当强制联网。最重要的是把这一步放在 outline / claims 定稿前，并显式分开“视频原话”“外部事实”“整理者推断”。

5.5 5. 历史 case 是否应该进一步利用？

应该，而且应该直接变成评测集。你们已经有足够典型的 case：

- `BV1cptBzFE5Q`: `static-outline`
- `BV1tj6wBDEXF`: `board-heavy`
- `BV1VaQrBPEg9`: `commentary`
- `bv1z9qzbgewv`: `visual-light`

下一步不应该只是“再做几次漂亮案例”，而是把这些 case 变成回归测试与 PDF QA 集。

6 建议的目标架构

6.1 总体设计：从字幕到 PDF 的六层链路

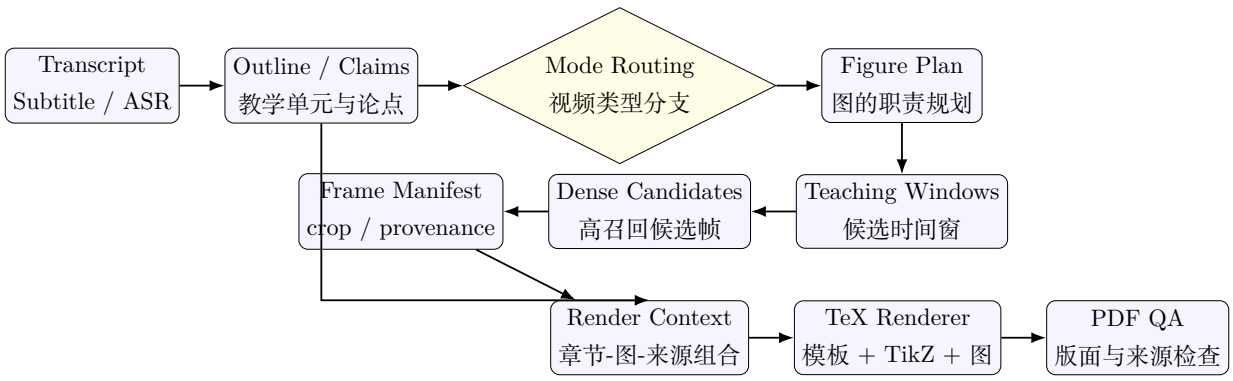

图 3: 建议的目标架构：在字幕与 TeX 之间加入结构化中间层，避免“直接从 transcript 跳成 PDF”

6.2 建议扩展的模式分类

当前 wrapper 只有 `talking-head`、`visual-light`、`static-outline`、`board-heavy` 四类。我建议至少补成六类：

表 4: 建议的 mode taxonomy

Mode	典型视觉特征	推荐图像策略
`talking-head`	人像主导，视觉内容稀薄	少量 representative frames，更多依赖结构化写作与自制图
`visual-light`	偶尔有关键 slide / product UI	overview 后做定向时间窗抽帧，保留少量关键图
`static-outline`	单页大纲、文字密、变化慢	整页锚点图 + 少量 detail-crop + TikZ，总体少截图
`board-heavy`	白板、手写、渐进累积	高召回候选图，优先最终完整态，必要时补中间步骤序列
`screen-demo`	软件界面、操作步骤、局部控件频繁变化	scene change + OCR/layout probe + detail-crop / sequence
`commentary`	画面只承担陪衬，价值在论证结构	少量代表帧 + 表格 / TikZ / 外部证据增强

6.3 针对每种模式的 figure workflow

6.3.1 `static-outline`

- 先通过 overview 确认“单画布 + 高亮推进”。
- 生成完整大纲页的高分辨率锚点图。
- 每章最多只保留 0–1 张 detail-crop。
- 优先用 TikZ、表格、总结框承担解释。

6.3.2 `board-heavy`

- 先在高价值窗口做 dense candidates。
- montage 后优先找“最终完整可读状态”。
- 候选图足够清晰时直接 crop-first。
- 只在文字或公式读不清时回源视频精抓。

6.3.3 `screen-demo`

- 把字幕单元与 scene change 结合，切到真正操作步骤窗口。
- 用 OCR / layout 估计可交互控件和主要信息区。
- 每个关键操作步骤导出 `full-screen` 与 `detail-crop`。
- 对连续操作用 2–4 张 progress sequence，而不是截满整段视频。

6.3.4 `commentary / analysis`

- 把截图数量控制在最小必要集。
- 重点投入在 outline、claim graph、对比表、因果链图。

- 如有必要，开启联网背景增强。
- 严格区分视频观点、外部事实和整理者推断。

6.4 推荐的目录树与 artifact 合约

```
case/
  assets/
  cover.jpg
  transcript.srt
  transcript.json
  outline.json
  claims.json
  figure_plan.json
  frame_manifest.json
  render_context.json
  evidence_enrichment.json   # optional
  figures/
    final/
    candidates/
    crops/
  montages/
  previews/
  note.tex
  note.pdf
  build.log
```

Listing 3: 建议固定的 case 目录树

artifact 管理原则

- `final`、`evidence`、`scratch` 必须分层。
- 编译垃圾不应和最终交付混在一起。
- 如果一次 run 做过后续精修，应保留 append-only run ledger，而不是只留下最终目录态。

6.5 PDF QA：不要再停在“编过就算”

建议把 PDF QA 固定成四类检查：

1. **结构检查**：章节顺序、目录、图文引用、总结章节是否完整。
2. **图像检查**：是否模糊、是否重复、是否裁掉关键信息、是否误抓动画过渡帧。
3. **provenance 检查**：每张视频图是否附具体时间区间，同页呈现是否稳定。
4. **版面检查**：跨页漂移、caption 溢出、公式截断、表格过窄、预览页抽检。

7 实施路线：按 ROI 排序

7.1 P0：先补最值钱的中间层

- 在 runtime 中新增 `capture_keyframes`：teaching windows → dense candidates → montage → crop-first → frame manifest
- 新增 `figure_plan.json` 与 `frame_manifest.json`
- 将 provenance 默认写法改成图下内嵌来源块
- 在 mode routing 中加入 `screen-demo` 与 `commentary / analysis`

7.2 P1：引入 probe 型视觉增强

- 接入 PySceneDetect，把字幕窗口进一步细分
- 接入 PaddleOCR layout analysis，专门服务于 slide / UI / document-heavy 画面
- 对公式密集 case 增加 formula probe
- 建立 crop quality / readability 的自动阈值

7.3 P2：引入更强的语义规划

- 让 agent / VLM 参与 `figure_plan.json` 的生成与覆写
- 引入 `evidence_enrichment.json`，按模式启用联网背景核验
- 用更显式的 claim graph 支撑正文结构与图的放置

7.4 P3：评估更远期替代方案

- 评估 TransNetV2 对 screen-demo / mixed-media 视频是否带来实质收益
- 小规模验证 Typst / Quarto 作为未来报告型模式的备选 renderer
- 仅当 LaTeX 模板演进成本成为瓶颈时，再考虑 renderer 迁移

8 评测集与验收指标

8.1 建议先固化四个 benchmark case

- `BV1cptBzFE5Q`：`static-outline`
- `BV1tj6wBDEXF`：`board-heavy`
- `BV1VaQrBPEg9`：`commentary / analysis`
- `bv1z9qzbgewv`：`visual-light`

(a) 最终整理出的代表帧组合图

1.2 本章小结

读这条视频时，最重要的不是记住几句热血表达，而是抓住它的结构：**身份**是起点，**目标系统**是过滤器，**反馈迭代**是推动器，**游戏化设计**是执行外壳。后面几章会按这条链逐层展开。

2 先改身份，不要只盯行为

2.1 为什么“逼自己坚持”往往只能持续两周

视频里最直白的一刀，是把很多人对“改变”的理解直接挑开：多数人想到改变，想到的是我要更努力、我要更自律、我要逼自己执行。但主播指出，这样做的问题在于，你仍然在用旧的自己去完成一个新的人才会稳定做出的事情。

这也是为什么很多目标会在一开始有冲劲，随后迅速回落。你并没有真的成为一个习惯于那种生活方式的人，只是短时间对自己施加了外部压力。

图 2: 视频强调的核心对比：强迫行为与身份驱动行为的差异

2.2 健身例子为什么重要

主播用长期健身的人做例子：如果一个人真的把“健康生活”纳入自我认同，他不需要每天花大量精神力说服自己去吃健康食物；相反，垃圾食品会让他觉得别扭。这个例子不是为了讲饮食，而是为了说明一个普遍规律：

- 当某个行为还只是目标时，它需要对抗惯性。
- 当某个行为已经并入身份，它会自动获得稳定性。

视频的原话里还有一个更关键的补充：真正的改变，不只是“开始做对的事”，而是**开始厌恶那些把你固定在原地的事情**。这说明改变成功的标志，不只是新增几个任务，而是旧行为的吸引力真的开始下降。

理解这一段时要抓住“自然性”

行为是否高级，不在于它看起来多难，而在于它是否已经进入你的默认状态。身份一旦改写，正确行为的主观难度会明显下降。

4

(b) 最终 PDF 页面示例

图 4: 本地现有 case 已经证明，只要 figure workflow 与图文规划到位，最终 PDF 可以明显好于原始 overview 抽样阶段

来源：左图 `/home/fanghaotian/Desktop/src/video_notes/bv1z9qzbgewv/figures/video_triptych.jpg`；右图 `/home/fanghaotian/Desktop/src/video_notes/bv1z9qzbgewv/pdf_preview/page-05.png`。

8.2 不要只测“能否出 PDF”

建议的核心指标包括：

表 5: 建议的验收指标

指标	解释	类型
Figure Readability	图中文字、公式、控件是否清晰可读	硬指标 + 人审
Figure Novelty	最终图之间是否大量重复	自动 + 人审
Figure Alignment	图是否真对应正文讨论的教学单元	人审主导
Provenance Completeness	每张视频图是否有时间区间、来源和 crop 记录	自动可检
Narrative Coherence	章节动机、图和正文是否相互支撑	人审主导
PDF Layout Stability	是否存在脚注漂移、图片裁切、页边溢出	自动预览 + 人审
Build Reproducibility	是否能在当前机器稳定复现产物	自动可检

8.3 建议的最小回归测试

- 结构测试：确保 `outline.json`、`claims.json`、`figure_plan.json`、`frame_manifest.json` 字段齐全
- 渲染测试：确保所有 figures 路径可解析，`note.tex` 可编译
- QA 测试：自动导出预览页，对重复图和缺失 provenance 做规则检查
- 回归测试：四个 benchmark case 的页数、图数量、核心图类型维持在合理范围内

9 风险、边界与不建议做的事

9.1 不要在没有中间层之前盲目上重型视觉模型

如果现在直接接入一堆 OCR、VLM、布局模型，但没有固定 artifact，很容易出现：

- 生成一堆额外 JSON，却不知道哪一层该消费；
- 同一张图被不同模块重复判断，结果互相冲突；
- agent prompt 更长，真实稳定性反而下降。

9.2 不要把 OCR 当作所有视频的默认解

本地 `commentary` case 已经证明 OCR 可以完全无效。OCR 应该是 probe，不是默认主干。

9.3 不要让联网增强改写“忠实讲义”的基本契约

对于教学视频，联网带来的背景补足很有价值，但不能悄悄把讲者的主张改写成整理者自己的文章。外部来源必须明确标注其角色。

9.4 不要把最好的 case 误当成“流程天然稳定产物”

你们已有的好案例里，有不少质量来自后续人工 refinement。如果未来要把这些能力真正下沉到 runtime，就必须保留 append-only run ledger，并把“这一步是自动稳定完成的”与“这一步是后期人工补救的”分开记录。

10 结论与后续问题

10.1 已经有充分证据支持的结论

- 当前问题的主轴不是“缺少图像工具”，而是“缺少字幕之后的结构化中间层”。
- 最值钱的升级是 figure workflow 产品化：teaching windows、dense candidates、crop-first、frame manifest、render context。
- mode routing 至少应补 `screen-demo` 与 `commentary / analysis` 两类。
- LaTeX 不是眼下的瓶颈；应优先修结构化输入与 provenance，而不是迁移 renderer。
- 历史 case 已足以构成 benchmark / eval 套件。

10.2 大概率正确但仍值得继续验证的推断

- PySceneDetect 会在 screen-demo 和 mixed-media 视频上带来明显收益，但在 `static-outline` 和 `board-heavy` 上收益可能有限。
- PaddleOCR layout / formula probe 对公式页、PPT 页、界面录屏会有明显价值，但对 commentary 价值不高。
- VLM 适合作为 `figure_plan` 的覆写器，而不适合直接替代确定性 frame workflow。

10.3 下一步最值得做的三件事

1. 在 `video-note-pipeline` 里实现 P0 版关键帧捕获层，核心产物为 `capture_keyframes`、`figure_plan.json` 与 `frame_manifest.json`。
2. 修正模板默认 provenance，并把 PDF QA 固定成流程的一部分。
3. 把四个典型 case 收敛成回归评测集，用来验证 mode routing 和 figure workflow 是否真正变稳定。

A 来源清单

Source ID	模态	标题 / 标签	链接或路径
L1	Local	旧 `bilibili-render-pdf` 规则	`/home/fanghaotian/.codex/skills/video-note-skill/skills/bilibili-render-pdf/SKILL.md`

Source ID	模态	标题 / 标签	链接或路径
L2	Local	统一 wrapper 模板注释	/home/fanghaotian/Desktop/src/agent-basic-skill/skills/video-note-render-pdf/assets/notes-template.tex
L3	Local	overview.py	/home/fanghaotian/Desktop/src/video-note-pipeline/src/video_note_pipeline/frames/overview.py
L4	Local	commands.py 中 overview_case	/home/fanghaotian/Desktop/src/video-note-pipeline/src/video_note_pipeline/commands.py
L5	Local	pyproject.toml	/home/fanghaotian/Desktop/src/video-note-pipeline/pyproject.toml
L6	Local	mode-routing.md	/home/fanghaotian/Desktop/src/agent-basic-skill/skills/video-note-render-pdf/references/mode-routing.md
L7	Local	BV1cptBzFE5Q retrospective	/home/fanghaotian/Desktop/src/video_notes/evlove/WORKFLOW_RETROSPECTIVE_BV1cptBzFE5Q_2026-03-25.md
L8	Local	BV1tj6wBDEXF retrospective	/home/fanghaotian/Desktop/src/video_notes/evlove/WORKFLOW_RETROSPECTIVE_BV1tj6wBDEXF_2026-03-25.md
L9	Local	BV1VaQrBPEg9 retrospective	/home/fanghaotian/Desktop/src/video_notes/evlove/WORKFLOW_RETROSPECTIVE_BV1VaQrBPEg9_2026-03-25.md
L10	Local	frame_manifest.json 示例	/home/fanghaotian/Desktop/src/video_notes/BV1tj6wBDEXF/frame_manifest.json
L11	Local	总复盘	/home/fanghaotian/Desktop/src/video_notes/evlove/WORKFLOW_RETROSPECTIVE_2026-03-25.md
W1	Web	FFmpeg Filters Documentation	https://ffmpeg.org/ffmpeg-filters.html
W2	Web	PySceneDetect Documentation	https://www.scenedetect.com/docs/latest/api/detectors.html
W3	Web	TransNetV2 GitHub README	https://github.com/soCzech/TransNetV2/blob/master/README.md
W4	Web	Lecture2Notes duplicate image removal	https://lecture2notes.readthedocs.io/en/latest/end-to-end/duplicate-image-removal.html
W5	Web	Lecture2Notes frame extraction	https://lecture2notes.readthedocs.io/en/latest/end-to-end/frame-extraction.html
W6	Web	video2slides PyPI	https://pypi.org/project/video2slides/
W7	Web	PaddleOCR Layout Analysis	https://www.paddleocr.ai/latest/en/version3.x/module_usage/layout_analysis.html
W8	Web	PaddleOCR Formula Recognition	https://www.paddleocr.ai/main/en/version3.x/module_usage/formula_recognition.html
W9	Web	docTR Documentation	https://mindee.github.io/doctr/latest/
W10	Web	LayoutParser	https://layout-parser.github.io/
W11	Web	PPT-master README	https://raw.githubusercontent.com/hugohe3/ppt-master/main/README.md

Source ID	模态	标题 / 标签	链接或路径
W12	Web	Quarto PDF Basics	https://quarto.org/docs/output-formats/pdf-basics.html
W13	Web	Typst Documentation	https://typst.app/docs/
W14	Web	Docling Documentation	https://docling-project.github.io/docling/

B 一个可直接执行的最小技术任务单

1. 在 runtime 新增 `capture_keyframes.py`，输入 `transcript.json + outline.json + mode`，输出 `candidates/`、`montages/`、`frame_manifest.json`。
2. 新增 `figure_plan.json`，每节至少给出图类型、解释职责、时间窗与 must-have 标记。
3. 把 LaTeX 模板里的 provenance 默认模式改成图下内嵌来源块。
4. 新增 `commentary` 与 `screen-demo` 路由，并为其分别定义 figure strategy。
5. 将 `BV1cptBzFE5Q`、`BV1tj6wBDEXF`、`BV1VaQrBPEg9`、`bv1z9qzbgewv` 固化为 benchmark case。